



UNIVERSIDAD
Panamericana

UNIVERSIDAD



Facultad de
Ingeniería

Sistemas Inteligentes

Proyecto Final: Sistema de Percepción Visual para Clasificación de Tumores Cerebrales (NeuroScan AI)

Integrantes: Melisa Ortiz Morante y Santiago Sepúlveda Landeros.

Especialidad: Automatización Inteligente

Fecha de Entrega: Miércoles 17 de Junio, 2026

Profesor: Andrés Emiliano Escobedo Gordillo

Índice

Planteamiento del problema y justificación de la solución.....	3
Arquitectura del modelo.....	4
Experimentación.....	6
Resultados.....	7
Conclusiones.....	10
Referencias.....	12

Planteamiento del problema y justificación de la solución.

Como equipo encontramos que el diagnóstico oncológico a través de imágenes de resonancia magnética es un trabajo crítico dentro de la oncología médica. El análisis manual de estos estudios —realizado por radiólogos— es un proceso exhaustivo, costoso en tiempo y altamente susceptible al error humano derivado de la fatiga visual o el cansancio general. Un retraso en la identificación del tipo de tumor impacta directamente en la tasa de supervivencia del paciente.

El entorno consiste en un flujo continuo de información visual que proviene de sensores de escaneo médico. En un entorno que es altamente incierto, complejo y dinámico debido a la variabilidad anatómica de los pacientes, las diferencias en la calibración y contraste de las máquinas de resonancia y la posible presencia de ruido o artefactos en las capturas. El agente por otro lado, se define como el sistema inteligente de percepción visual computacional diseñado para percibir este entorno incierto y mapear las características espaciales de los píxeles hacia un estado de diagnóstico clínico correcto.

Como justificación técnica planteamos que: los patrones morfológicos, texturas y fronteras que diferencian un tejido cerebral sano de uno tumoral representan relaciones estadísticas de alta no linealidad. Por ello los enfoques de los algoritmos tradicionales que se basan en sistemas de reglas fijos son inviables para resolver el problema bajo condiciones reales de incertidumbre. Una red neuronal convolucional es la mejor técnica para este escenario que trabajamos en el proyecto final ya que posee la capacidad matemática de aprender abstracciones y extraer características jerárquicas especiales de forma automatizada; esto garantiza adaptabilidad y robustez ante las variaciones que puedan salir en el entorno médico.


Arquitectura del modelo.

- **Selección de la Red Base.-**

Implementamos una arquitectura *EfficientNetB0* presentada en el conjunto de datos a gran escala *ImageNet-1K*. La red la seleccionamos porque su diseño está basado en el escalamiento compuesto el cual balancea la profundidad, el ancho de las capas y la resolución de la imagen. Esto permite procesar la alta complejidad visual del entorno con una carga computacional que sea eficiente, operando así con aproximadamente 5.3 millones de parámetros.

- **Modificaciones para el target.-**

El clasificador original (EfficientNetB0) está diseñado para identificar mil clases de objetos cotidianos; partiendo de esto tuvimos que realizar una reestructuración de la red mediante la técnica de Transfer Learning o aprendizaje por transferencia y Fine Tuning. Realizamos 2 principales acciones con esta reestructura: primero, se removió la capa de salida original de la red. Segundo, se acopló a una nueva cabeza de clasificación completamente conectada adaptada al espacio de estados del problema, que en nuestro caso para este proyecto son 4 clases clínicas: Glioma, Meningioma, Sin Tumor y Tumor Pituitario.



Total entrenamiento: 5,600 imágenes

Clase más pequeña: 1400 | más grande: 1400

Ratio max/min: 1.00x → dataset completamente balanceado ✓

Imagen 1: Distribución de las 4 clases en nuestro código.

- **Mecanismos de Regularización y Transferencia (Dropout).-**

Integramos capas de dropout en la cabeza del clasificador para apagar neuronas de manera aleatoria durante el entrenamiento forzando a la red a no codependencia de características que estén aisladas y así mitigar el riesgo de que se sobreajuste.

También, para eliminar el comportamiento de caja negra que está presente en las redes profundas y a la vez cumplir con rigor médico, decidimos implementar el algoritmo de Gradiente weighted Class Activation Mapping. Este método calcula de manera matemática los gradientes de la puntuación de la clase predicha con respecto a los mapas de características de la última capa convolucional de la red. El resultado que nos dio es un mapa de calor espacial que se superpone a la resonancia, proporcionando de esta manera evidencia visual exacta de la región anatómica en la que el agente fundamentó su decisión diagnóstica.




Imagen 2: Resultado del Grad CAM en nuestro código.

Experimentación.

- **Metodología y Pipeline de Datos.-**

El flujo de trabajo se fue documentando en el Jupyter Notebook y utilizamos la GPU Nvidia T4. Asimismo obtuvimos los datos de Kaggle y a partir de esto tenemos el conjunto de entrenamiento y el de prueba.

Primero, el conjunto de entrenamiento está compuesto por 5,600 imágenes. Revisamos cuidadosamente la estructura del dataset para que fuera balanceado, con un ratio exacto de 1.0x entre clases (1,400 imágenes por cada una de las 4 categorías), eliminando cualquier sesgo que pueda tener el algoritmo previo al entrenamiento.

Segundo, el conjunto de prueba que fue separado de forma estricta desde el inicio con 1,600 imágenes en total que son 400 por clase para asegurar una evaluación imparcial de la capacidad de generalización del agente.

- **Procesamiento y Aumentación.-**

Las imágenes fueron redimensionadas a la resolución nativa de la arquitectura (224 x 224 píxeles) y se aplicó una normalización de canales basada en la media y desviación estándar de ImageNet. Se aplicaron técnicas de aumentación de datos en el set de entrenamiento para simular variaciones físicas del entorno (como rotaciones ligeras, ajustes de contraste y traslaciones).

- **Hiperparámetros y Estrategia de Entrenamiento.-**

Para la función de costo seleccionamos la función de pérdida de entropía cruzada multiclase, la cual mide de forma matemática la divergencia entre la distribución de la probabilidad real de las etiquetas clínicas y las predicciones probabilísticas del modelo.

El entrenamiento lo estructuramos de forma iterativa aplicando un optimizador estándar y un programador de tasa de aprendizaje, el cual redujo dinámicamente el tamaño del paso de gradiente a medida que la pérdida se estabilizará para afinar los pesos de manera precisa.

También implementamos una política de early stopping, la cual monitorea la pérdida en el conjunto de validación de manera continua. El entrenamiento se interrumpió de forma automática en el momento en el que esa pérdida deja de disminuir, lo que impide que el agente memorice el ruido del conjunto de entrenamiento.

Resultados.

En esta sección mostraremos los resultados de todo lo que se explicó en la sección anterior. Una vez que se realizó el proceso de entrenamiento y la ejecución de las inferencias sobre el conjunto de pruebas estrictamente aislado, el sistema reportó los siguientes indicadores de rendimiento:

Indicador de rendimiento	Resultado
Pérdida de Validación Final	0.0774
Exactitud en Test	~ 97%
F-1 Score Macro	~0.97

```
[F2] Época 30/30 | train_loss=0.0920 acc=0.969 | val_loss=0.0774 acc=0.973
📁 Mejor modelo guardado (val_loss=0.0774)

✅ Entrenamiento completo – mejor modelo en best_model.pt
```

Imagen 3: Resultado del Entrenamiento.

- **Análisis de Convergencia.-**

Las curvas de aprendizaje que generamos demuestran una trayectoria de optimización muy estable, donde la pérdida de validación decrece en paridad con la pérdida de entrenamiento, confirmando la ausencia de sobreajuste. También, la matriz de confusión resultante exhibe una tasa de error marginal y simétrica, validando la robustez del agente para discriminar con precisión incluso entre las firmas morfológicas más complejas y similares.




Imagen 4 : Curvas de aprendizaje generadas.




Imagen 5 : Matriz de confusión generada que compara tasa de error marginal vs simétrica.

Al final con ayuda de Grad- CAM y el análisis que lleva a cabo el sistema, logramos que al final dé una respuesta visual para quien utiliza el mismo, mostrando la probabilidad en un grafico de barras y mostrando la comparación de las imagenes (blanco y negro y la imagen con el mapa de calor).




Imagen 6: Resultado final (Predicción).

Un accuracy y un F1-Score del 97% implica que en la operación cotidiana de una organización de salud, el sistema logrará clasificar de manera correcta 97 de cada 100 pacientes de forma inmediata.

Poner este modelo en un entorno productivo real no significa sustituir el criterio del especialista humano, sino transformarlo en un sistema de triaje de alta velocidad:

- 1) El agente procesa de manera masiva y en milisegundos el flujo entrante de imágenes de resonancia magnética en los servidores del hospital.
- 2) Identifica de forma instantánea los casos que presentan anomalías tumorales y los etiqueta con una prioridad roja o urgente en el sistema informático clínico.
- 3) Reorganiza de forma automática la lista de espera de lecturas de radiología, asegurando que los casos críticos pasen al inicio de la cola para recibir la revisión médica urgente. Esto optimiza el flujo de trabajo hospitalario y reduce drásticamente el tiempo de respuesta diagnóstica en casos severos.

Conclusiones.

El desarrollo de NeuroScan AI valida que los sistemas de percepción visual profunda, fundamentados en el aprendizaje por transferencia , son herramientas de alta confiabilidad matemática capaces de mitigar la incertidumbre e interpretar variaciones anatómicas complejas en entornos médicos reales.

- **Puntos fuertes del proyecto.-**

El balance perfecto de la muestra inicial previene el sesgo predictivo, lo que garantiza que el modelo sea igual de preciso para todas las patologías evaluadas.

También realizamos una integración exitosa de Grad-CAM lo cual aporta un sentido ético y de auditoría visual esencial para que el sistema sea adoptado con confianza por los profesionales de la salud; facilitando así futuros procesos de certificación regulatoria como software de soporte de diagnóstico.

Finalmente, el pipeline modular y reproducible que se ejecuta con tiempos mínimos de inferencia gracias a la optimización de *EfficientNetB0*.

- **Puntos débiles del proyecto.-**

El desempeño del agente está ligado a que el escaneo de entrada conserve ciertos estándares de encuadre y limpieza técnica mínimos. Ruido extremo no controlado o variaciones de ángulo atípicas en las máquinas de MRI podrían degradar la precisión del modelo. Asimismo, el alcance actual del sistema se encuentra acotado a un espacio discreto de 4 salidas exclusivas, sin contemplar de momento otras patologías cerebrales o incluso diagnósticos mixtos. Adicionalmente, encontramos una debilidad que se conecta con el trabajo futuro el cual es que en 34 instancias dijo que no era tumor algo que era un glioma, por lo que para resolverlo en situaciones futuras podemos re entrenar con oversampling de muestras de gliomas. Sin embargo, pensamos que porcentualmente es suficientemente bajo de modo que si se procesan varias tomas del mismo paciente en alguna se detectaría, entonces no es un problema crucial en la detección de cáncer.

Por último, sobre el trabajo futuro pensamos en lo siguiente: empaquetar el agente dentro de un contenedor de software como lo es un Docker y exponerlo mediante una API que se conecte de forma directa al protocolo estandarizado DICOM o PACS (el formato que

es utilizado en hospitales de forma universal), permitiendo que el modelo pueda recibir y procesar datos directamente desde los escáneres.

Finalmente, implementar una interfaz de retroalimentación en donde los radiólogos puedan corregir de forma manual los falsos positivos o negativos detectados por el sistema en producción. Estas correcciones serán almacenadas automáticamente como nuevos datos etiquetados para realizar entrenamientos de forma periódica controlada del agente, permitiendo que el sistema se adapte y evolucione con base en la experiencia clínica real.

Referencias.

- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., ... & Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems*, 32, 8024–8035.
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. En *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* (pp. 618-626). <https://ieeexplore.ieee.org/document/8237336>
- Tan, M., & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. En *Proceedings of the 36th International Conference on Machine Learning (ICML)* (Vol. 97, pp. 6105-6114). PMLR.